

Informe Técnico: Sistema GLM de Detección, Tracking y Pronóstico de Tormentas

Información General del Proyecto

Desarrollador: Matias

Fecha: Mayo 2025

Versión del Sistema: 2.0

Lenguaje Principal: Python 3.x

Fuente de Datos: GOES-R Geostationary Lightning Mapper (GLM)

1. Resumen Ejecutivo

El sistema desarrollado constituye una plataforma integral para la detección, seguimiento y pronóstico de tormentas eléctricas utilizando datos satelitales del GLM. El sistema procesa datos de descargas eléctricas en tiempo cuasi-real, identifica celdas convectivas, rastrea su evolución temporal y genera pronósticos con cuantificación de incertidumbre mediante técnicas de machine learning.

Características Principales:

- Procesamiento automatizado** de datos GLM en formato NetCDF
- Identificación inteligente** de celdas de tormenta usando clustering DBSCAN
- Tracking robusto** con algoritmos de optimización combinatorial
- Pronóstico automático** con ensemble de modelos de ML
- Verificación continua** de predicciones con métricas estándar
- Visualización interactiva** con mapas web y dashboards de rendimiento

2. Arquitectura del Sistema

2.1 Estructura Modular

El sistema está organizado en 8 módulos principales interconectados:

Sistema GLM Nowcasting

- └─ Procesamiento de Datos (glm_processor.py)
- └─ Identificación de Celdas (flash_cell_identification.py)
- └─ Tracking de Celdas (improved_flash_cell_tracking.py)
- └─ Nowcasting/Pronóstico (improved_flash_cell_nowcasting.py)
- └─ Verificación y Métricas (verification_and_performance_metrics.py)
- └─ Evaluación de Rendimiento (nowcasting_evaluator.py)
- └─ Visualización (enhanced_lightning_visualizer.py)
- └─ Orquestación (run_historical_analysis.sh)

2.2 Flujo de Procesamiento

1. **Descarga y Lectura** de datos GLM
 2. **Extracción de Flashes** con timestamps corregidos
 3. **Clustering espacial** para identificar celdas
 4. **Tracking temporal** de celdas entre ventanas
 5. **Generación de pronósticos** con ML
 6. **Verificación automática** de predicciones
 7. **Visualización** y análisis de resultados
-

3. Descripción Detallada de Módulos

3.1 GLMProcessor (glm_processor.py)

Propósito: Procesamiento y extracción de datos del Geostationary Lightning Mapper.

Funcionalidades:

- Lectura de archivos NetCDF GLM con manejo robusto de errores
- Filtrado temporal de archivos usando patrones de fecha
- Extracción de datos de flashes con corrección de timestamps
- Normalización de coordenadas geográficas
- Agregación de datos por ventanas temporales

Algoritmos Implementados:

- Conversión de día juliano a fecha calendario
- Manejo simplificado de timestamps GLM con fallbacks
- Filtrado automático por rango temporal

Salidas:

- DataFrames de pandas con datos de flashes procesados
- Metadatos temporales y geográficos

3.2 FlashCellIdentifier (flash_cell_identification.py)

Propósito: Identificación automática de celdas convectivas mediante clustering espacial.

Funcionalidades:

- Clustering DBSCAN adaptativo con parámetros dinámicos
- Creación de envolturas convexas (convex hulls) para geometrías
- Cálculo de estadísticas por celda (área, intensidad, energía)
- Detección garantizada de todas las tormentas visibles
- Agrupamiento manual alternativo para casos complejos

Algoritmos Implementados:

- DBSCAN con normalización StandardScaler
- Convex Hull usando scipy.spatial
- Búsqueda por conectividad para agrupamiento manual
- Cálculo de métricas geométricas

Parámetros Configurables:

- `eps`: Distancia máxima entre muestras (default: 0.05)
- `min_samples`: Número mínimo de muestras por cluster (default: 5)
- `use_time_weight`: Incorporar peso temporal en clustering

3.3 ImprovedFlashCellTracker (improved_flash_cell_tracking.py)

Propósito: Seguimiento temporal robusto de celdas con predicción de movimiento.

Funcionalidades:

- Tracking multi-criterio con función de similitud avanzada
- Resolución del problema de asignación usando algoritmo húngaro
- Predicción de posición usando regresión lineal multipunto
- Adaptación dinámica de umbrales según condiciones
- Gestión automática de tracks perdidos y nuevos

Algoritmos Implementados:

- Algoritmo húngaro para asignación óptima (scipy.optimize.linear_sum_assignment)

- Distancia Haversine para cálculos geográficos precisos
- Predicción por regresión lineal con histórico de posiciones
- Función de similitud multicriterio ponderada

Parámetros Configurables:

- `max_distance_km`: Distancia máxima para asociación (default: 30 km)
- `max_speed_kmh`: Velocidad máxima realista (default: 120 km/h)
- `intensity_weight`: Peso para similitud de intensidad (default: 0.3)
- `size_weight`: Peso para similitud de tamaño (default: 0.2)
- `shape_weight`: Peso para similitud de forma (default: 0.1)
- `prediction_weight`: Peso para predicción de posición (default: 0.4)
- `overlap_threshold`: Umbral mínimo de solapamiento (default: 0.1)

3.4 SmartImprovedFlashCellNowcaster (`improved_flash_cell_nowcasting.py`)

Propósito: Sistema de pronóstico inteligente con machine learning y ensemble de modelos.

Funcionalidades:

- Entrenamiento automático de Random Forest con datos acumulados
- Ensemble de modelos (físico, lineal, ML) con pesos adaptativos
- Cuantificación de incertidumbre con intervalos de confianza
- Extracción automática de características de tracking
- Persistencia y carga de modelos entrenados

Algoritmos Implementados:

- Random Forest para pronóstico multivariable
- Regresión lineal mejorada con múltiples puntos históricos
- Modelo físico con restricciones de velocidad
- Ensemble ponderado con optimización de pesos

Parámetros Configurables:

- `forecast_minutes`: Tiempo de pronóstico (default: 20 min)
- `min_history_points`: Puntos mínimos de historial (default: 2)
- `ensemble_models`: Usar ensemble de modelos (default: True)
- `uncertainty_quantification`: Calcular incertidumbre (default: True)
- `min_training_samples`: Muestras mínimas para entrenar RF (default: 50)

3.5 PerformanceVerificationSystem (verification_and_performance_metrics.py)

Propósito: Sistema integral de verificación de predicciones y análisis de rendimiento.

Funcionalidades:

- Verificación automática de predicciones contra observaciones
- Cálculo de métricas estándar (error posicional, intensidad, área)
- Análisis de calibración de confianza
- Generación de recomendaciones automáticas
- Exportación de reportes detallados en JSON

Métricas Implementadas:

- Error de posición (distancia Haversine)
- Error de intensidad (absoluto y porcentual)
- Error de área (absoluto y porcentual)
- Calibración de confianza por intervalos
- Tendencias temporales de rendimiento

Parámetros Configurables:

- `tolerance_minutes`: Tolerancia temporal para verificación (default: 25 min)

3.6 NowcastingEvaluator (nowcasting_evaluator.py)

Propósito: Evaluación completa del rendimiento del sistema con métricas meteorológicas estándar.

Funcionalidades:

- Cálculo de métricas de verificación (POD, FAR, CSI)
- Análisis de patrones de error por categorías
- Generación de mapas interactivos de errores
- Visualizaciones estadísticas de distribuciones de error
- Análisis de contingencia detallado

Métricas Meteorológicas:

- POD (Probability of Detection)
- FAR (False Alarm Ratio)
- CSI (Critical Success Index)
- RMSE, MAE para errores de posición

Parámetros Configurables:

- `position_tolerance_km`: Tolerancia posicional para aciertos (default: 10 km)

3.7 EnhancedLightningVisualizer (enhanced_lightning_visualizer.py)

Propósito: Visualización avanzada con mapas interactivos y dashboards de rendimiento.

Funcionalidades:

- Mapas consolidados con Folium mostrando historial completo
- Zonas de incertidumbre como elipses concéntricas
- Trayectorias históricas de tracks con información detallada
- Paneles de métricas en tiempo real
- Dashboard de rendimiento con gráficos matplotlib
- Leyendas interactivas y controles de capas

Elementos Visuales:

- Celdas actuales con polígonos y estadísticas
- Predicciones con flechas direccionales
- Zonas de confianza en múltiples niveles
- Verificaciones con código de colores
- Panel de métricas de rendimiento en vivo

3.8 Script de Orquestación (run_historical_analysis.sh)

Propósito: Automatización completa del procesamiento histórico con descarga de datos.

Funcionalidades:

- Descarga automática de datos GLM por rangos temporales
- Configuración de directorios y logging
- Manejo de múltiples días y rangos horarios
- Procesamiento por bloques de 10 minutos
- Logging detallado de operaciones

4. Parámetros Configurables del Sistema

4.1 Parámetros de Procesamiento GLM

Parámetro	Ubicación	Default	Descripción
<code>data_dir</code>	GLMProcessor	None	Directorio de datos GLM
<code>start_time</code>	GLMProcessor	None	Tiempo de inicio del procesamiento
<code>end_time</code>	GLMProcessor	None	Tiempo de fin del procesamiento

4.2 Parámetros de Identificación de Celdas

Parámetro	Ubicación	Default	Descripción
<code>eps</code>	FlashCellIdentifier	0.05	Distancia máxima DBSCAN
<code>min_samples</code>	FlashCellIdentifier	5	Muestras mínimas por cluster
<code>use_time_weight</code>	FlashCellIdentifier	True	Usar peso temporal

4.3 Parámetros de Tracking

Parámetro	Ubicación	Default	Descripción
<code>max_distance_km</code>	ImprovedFlashCellTracker	30	Distancia máxima de asociación (km)
<code>max_speed_kmh</code>	ImprovedFlashCellTracker	120	Velocidad máxima realista (km/h)
<code>intensity_weight</code>	ImprovedFlashCellTracker	0.3	Peso similitud intensidad
<code>size_weight</code>	ImprovedFlashCellTracker	0.2	Peso similitud tamaño
<code>shape_weight</code>	ImprovedFlashCellTracker	0.1	Peso similitud forma
<code>prediction_weight</code>	ImprovedFlashCellTracker	0.4	Peso predicción posición
<code>overlap_threshold</code>	ImprovedFlashCellTracker	0.1	Umbral solapamiento
<code>time_delta_minutes</code>	ImprovedFlashCellTracker	10	Ventana temporal (min)

4.4 Parámetros de Nowcasting

Parámetro	Ubicación	Default	Descripción
<code>forecast_minutes</code>	SmartImprovedFlashCellNowcaster	20	Tiempo de pronóstico (min)
<code>min_history_points</code>	SmartImprovedFlashCellNowcaster	2	Puntos mínimos historial
<code>ensemble_models</code>	SmartImprovedFlashCellNowcaster	True	Usar ensemble modelos
<code>uncertainty_quantification</code>	SmartImprovedFlashCellNowcaster	True	Calcular incertidumbre
<code>min_training_samples</code>	SmartImprovedFlashCellNowcaster	50	Muestras mínimas RF
<code>n_estimators</code>	Random Forest	100	Número de árboles RF
<code>max_depth</code>	Random Forest	10	Profundidad máxima RF
<code>min_samples_split</code>	Random Forest	5	Muestras mínimas split
<code>min_samples_leaf</code>	Random Forest	2	Muestras mínimas hoja

4.5 Parámetros de Verificación

Parámetro	Ubicación	Default	Descripción
tolerance_minutes	PerformanceVerificationSystem	25	Tolerancia temporal (min)

4.6 Parámetros de Evaluación

Parámetro	Ubicación	Default	Descripción
position_tolerance_km	NowcastingEvaluator	10	Tolerancia posicional (km)

4.7 Parámetros del Script Principal

Parámetro	Script	Default	Descripción
--window_minutes	run_historical_analysis.sh	10	Ventana temporal (min)
--forecast_minutes	run_historical_analysis.sh	20	Tiempo pronóstico (min)
--eps	run_historical_analysis.sh	0.05	Parámetro eps DBSCAN
--min_samples	run_historical_analysis.sh	5	Min samples DBSCAN
--visualize	run_historical_analysis.sh	False	Generar visualizaciones
--animation	run_historical_analysis.sh	False	Crear animación
--validation	run_historical_analysis.sh	False	Realizar validación
--debug	run_historical_analysis.sh	False	Logging debug
--use-advanced-models	run_historical_analysis.sh	False	Usar modelos ML
--show-uncertainty	run_historical_analysis.sh	False	Mostrar incertidumbre
--predict-shape	run_historical_analysis.sh	False	Predecir evolución forma
--evaluate	run_historical_analysis.sh	False	Evaluación detallada

5. Algoritmos y Técnicas Implementadas

5.1 Clustering y Detección

DBSCAN Adaptativo:

- Normalización con StandardScaler
- Parámetros dinámicos según densidad de datos
- Fallback a agrupamiento manual por conectividad

Geometría Computacional:

- Convex Hull para límites de celdas
- Cálculo de áreas geográficas
- Detección de solapamientos geométricos

5.2 Tracking y Asociación

Algoritmo Húngaro:

- Optimización combinatorial para asignación
- Matriz de costos basada en similitud multicriterio
- Minimización global de errores de asociación

Función de Similitud Multicriterio:

- Factor de distancia con decay exponencial
- Similitud de intensidad y tamaño
- Predicción de movimiento con regresión
- Solapamiento geométrico

5.3 Machine Learning y Pronóstico

Random Forest Multioutput:

- Predicción simultánea de [lat, lon, intensidad, área]
- Entrenamiento incremental con datos acumulados
- Validación cruzada implícita

Ensemble de Modelos:

- Modelo físico con restricciones de velocidad
- Regresión lineal multipunto
- Random Forest entrenado
- Pesos adaptativos según rendimiento

5.4 Verificación y Métricas

Métricas Estándar:

- Distancia Haversine para errores posicionales
- Errores relativos para intensidad y área
- Métricas categóricas (POD, FAR, CSI)

Análisis de Calibración:

- Intervalos de confianza por percentiles
 - Diagrama de confiabilidad implícito
 - Ajuste de niveles de confianza
-

6. Rendimiento y Escalabilidad

6.1 Optimizaciones Implementadas

Procesamiento Eficiente:

- Clustering con scipy optimizado
- Matrices numpy para cálculos vectorizados
- Lazy loading de datos NetCDF
- Cacheo de modelos entrenados

Gestión de Memoria:

- Liberación explícita de datasets xarray
- Procesamiento por ventanas temporales
- Límites en tamaño de historial de tracking

6.2 Capacidades del Sistema

Volumen de Datos:

- Procesamiento de múltiples días simultáneamente
- Manejo de miles de flashes por ventana temporal
- Seguimiento de hasta 20+ tracks simultáneos

Tiempo Real:

- Procesamiento en ventanas de 10 minutos
 - Latencia típica < 30 segundos por ventana
 - Pronósticos generados automáticamente
-

7. Salidas y Productos

7.1 Archivos de Datos

GeoJSON:

- Celdas identificadas con geometrías
- Metadatos temporales y estadísticas
- Información de tracking

CSV:

- Predicciones con coordenadas y confianza

- Métricas de verificación
- Estadísticas de rendimiento

Pickle:

- Modelos Random Forest entrenados
- Datos de entrenamiento acumulados
- Estado del sistema para continuidad

7.2 Visualizaciones

Mapas Interactivos (HTML):

- Folium con capas superpuestas
- Controles de tiempo y zoom
- Popups informativos detallados

Dashboards de Rendimiento:

- Gráficos matplotlib embebidos
- Métricas en tiempo real
- Análisis de tendencias temporales

Reportes de Verificación (JSON):

- Métricas agregadas por período
 - Detalles de verificaciones individuales
 - Recomendaciones automáticas
-

8. Casos de Uso y Aplicaciones

8.1 Nowcasting Operacional

Aplicaciones Meteorológicas:

- Predicción de desarrollo de tormentas
- Alertas tempranas de actividad eléctrica
- Seguimiento de sistemas convectivos

Sectores de Aplicación:

- Aviación (rutas y operaciones aeroportuarias)
- Agricultura (protección de cultivos)
- Eventos al aire libre (deportes, festivales)

- Energía eléctrica (protección de redes)

8.2 Investigación Científica

Análisis Climatológico:

- Patrones estacionales de actividad eléctrica
- Evolución temporal de sistemas convectivos
- Validación de modelos numéricos

Estudios de Verificación:

- Evaluación de métodos de pronóstico
 - Comparación de técnicas de ML
 - Optimización de parámetros
-

9. Requisitos Técnicos

9.1 Dependencias de Software

Python 3.x con librerías:

- numpy, pandas, scipy (computación científica)
- xarray, netCDF4 (datos satelitales)
- sklearn (machine learning)
- geopandas, shapely (datos geoespaciales)
- folium (visualización web)
- matplotlib (gráficos)

Herramientas del Sistema:

- Bash shell para scripts de automatización
- Suficiente espacio en disco para datos GLM
- Acceso a internet para descarga de datos

9.2 Recursos Computacionales

Mínimos Recomendados:

- RAM: 8 GB (16 GB recomendado)
- CPU: 4 cores (8 cores recomendado)
- Almacenamiento: 100 GB para datos históricos
- Red: Conexión estable para descarga GLM

10. Limitaciones y Consideraciones

10.1 Limitaciones Técnicas

Datos GLM:

- Disponibilidad limitada a cobertura satelital GOES
- Resolución temporal fija (20 segundos)
- Posibles interrupciones de servicio

Algoritmos:

- DBSCAN sensible a densidad de datos
- Random Forest requiere entrenamiento inicial
- Tracking puede fallar en celdas muy rápidas

10.2 Consideraciones Operacionales

Configuración Inicial:

- Ajuste de parámetros según región geográfica
- Período de entrenamiento para modelos ML
- Validación con casos conocidos

Mantenimiento:

- Monitoreo de rendimiento continuo
- Reentrenamiento periódico de modelos
- Actualización de umbrales según estación

11. Conclusiones y Recomendaciones

11.1 Fortalezas del Sistema

Arquitectura Robusta:

- Diseño modular permite fácil mantenimiento
- Algoritmos estado-del-arte para cada componente
- Verificación automática garantiza calidad

Capacidades Avanzadas:

- Machine learning adaptativo mejora con uso

- Cuantificación de incertidumbre aumenta confiabilidad
- Visualización interactiva facilita interpretación

11.2 Áreas de Mejora Futura

Algoritmos:

- Incorporar modelos de deep learning
- Fusión con datos de radar meteorológico
- Predicción de intensidad de precipitación

Operacional:

- Interfaz web para usuarios no técnicos
- Alertas automáticas configurable
- Integración con sistemas meteorológicos existentes

Rendimiento:

- Paralelización para procesamiento más rápido
- Optimización para tiempo real estricto
- Escalado horizontal para múltiples regiones

Información de Contacto

Desarrollador: Matias

Fecha del Informe: Junio 2025

Versión del Documento: 1.0

Este documento constituye la documentación técnica completa del Sistema GLM de Detección, Tracking y Pronóstico de Tormentas desarrollado en Mayo 2025.